



无监督深度学习

Unsupervised Deep Learning



01

无监督特征学习

(Unsupervised Feature Learning)

02

概率密度估计

(Probability Density Estimation)

03

小结(Summary)



■ 监督学习vs无监督学习

• 监督学习

- 建立映射关系 $f: x \rightarrow y$


• 无监督学习

- 指从无标签的数据中学习出一些有用的模式，包括有效的特征、类别、结构以及概率分布等。
 - **聚类**：建立映射关系 $f: x \rightarrow y$
 - 不借助于任何人工给出标签或者反馈等指导信息
 - **特征学习**：是从无标签的训练数据中挖掘有效的特征或表示。无监督特征学习一般用来进行降维、数据可视化或监督学习前期的数据预处理。
 - **密度估计** $p(x)$ ：，根据一组训练样本来估计样本空间的概率密度。
 - 密度估计可以分为参数密度估计和非参数密度估计


自监督学习: <https://www.bilibili.com/video/av88129135/>




■ 典型的无监督学习



无监督特征学习



概率密度估计



聚类

为什么要无监督学习？

大脑有大约 10^{14} 个突触，我们只能活大约 10^9 秒。所以我们有比数据更多的参数。这启发了我们必须进行大量无监督学习的想法，因为感知输入（包括本体感受）是我们可以获得每秒 10^5 维约束的唯一途径。

-- Geoffrey Hinton, 2014 AMA on Reddit

The Next AI Revolution Y. LeCun



With thanks to Alyosha Efros and Gil Scott Heron

Get the T-shirt!

Jitendra Malik: "Labels are the opium of the machine learning researcher"

PART ONE

无监督特征学习

Unsupervised Feature Learning

■ 无监督特征学习

- 无监督特征学习是指从无标注的数据中自动学习有效的数据表示，从而能够帮助后续的机器学习模型更快速地达到更好的性能。无监督特征学习主要方法有：
 - 主成分分析(**Principal Component Analysis, PCA**)
 - 稀疏编码(**Sparse Coding, SC**)
 - 自编码器(**Auto-Encoder, AE**)
 - 稀疏自编码器(**Sparse Auto-Encoder, SAE**)
 - 降噪自编码器(**Denoising Auto-Encoder, DAE**)

■ 主成分分析(PCA)

- 一种最常用的数据降维方法，使得在转换后的空间中数据的方差最大。

对目标函数求导并令导数等于 0，可得

$$\Sigma \mathbf{w} = \lambda \mathbf{w}$$

- 样本点 $\mathbf{x}^{(n)}$ 投影之后的表示为


$$\mathbf{z}^{(n)} = \mathbf{w}^\top \mathbf{x}^{(n)}$$

- 所有样本投影后的方差为


$$\begin{aligned}\sigma(\mathbf{X}; \mathbf{w}) &= \frac{1}{N} \sum_{n=1}^N (\mathbf{w}^\top \mathbf{x}^{(n)} - \mathbf{w}^\top \bar{\mathbf{x}})^2 \\ &= \frac{1}{N} (\mathbf{w}^\top \mathbf{X} - \mathbf{w}^\top \bar{\mathbf{X}})(\mathbf{w}^\top \mathbf{X} - \mathbf{w}^\top \bar{\mathbf{X}})^\top \\ &= \mathbf{w}^\top \Sigma \mathbf{w},\end{aligned}$$

- 目标函数

$$\max_{\mathbf{w}} \mathbf{w}^\top \Sigma \mathbf{w} + \lambda(1 - \mathbf{w}^\top \mathbf{w})$$



将这些数据投影到一维空间中，选择数据**方差最大**的方向进行投影，才能最大化数据的差异性，保留更多的原始数据信息。



■ 主成分分析(PCA)

- 一种最常用的数据降维方法，使得在转换后的空间中数据的方差最大。

- 样本点 $\mathbf{x}^{(n)}$ 投影之后的表示为

$$\mathbf{z}^{(n)} = \mathbf{w}^\top \mathbf{x}^{(n)}$$

- 所有样本投影后的方差为

$$\begin{aligned}\sigma(\mathbf{X}; \mathbf{w}) &= \frac{1}{N} \sum_{n=1}^N (\mathbf{w}^\top \mathbf{x}^{(n)} - \mathbf{w}^\top \bar{\mathbf{x}})^2 \\ &= \frac{1}{N} (\mathbf{w}^\top \mathbf{X} - \mathbf{w}^\top \bar{\mathbf{X}})(\mathbf{w}^\top \mathbf{X} - \mathbf{w}^\top \bar{\mathbf{X}})^\top \\ &= \mathbf{w}^\top \Sigma \mathbf{w},\end{aligned}$$


- 目标函数

$$\max_{\mathbf{w}} \mathbf{w}^\top \Sigma \mathbf{w} + \lambda(1 - \mathbf{w}^\top \mathbf{w})$$

将这些数据投影到一维空间中，选择数据方差最大的方向进行投影，才能最大化数据的差异性，保留更多的原始数据信息。



对目标函数求导并令导数等于 0，可得

$$\Sigma \mathbf{w} = \lambda \mathbf{w}$$




■ 主成分分析(PCA)

- 主成分分析可以转换成一个矩阵特征值分解问题，投影向量 $\mathbf{w}$ 为矩阵 Σ 的最大特征值对应的特征向量。
- PCA 的目标是寻找 r ($r < n$) 个新变量，使它们反映事物的主要特征，压缩原有数据矩阵的规模，将特征向量的维数降低，挑选出最少的维数来概括最重要特征。



■ 主成分分析(PCA)



设有 m 条 n 维数据:

1. 将原始数据按列组成 n 行 m 列矩阵 X ;
2. 将 X 的每一行进行零均值化, 即减去这一行的均值;
3. 求出协方差矩阵 $C = \frac{1}{m} XX^T$;
4. 求出协方差矩阵的特征值及对应的特征向量;
5. 将特征向量按对应特征值大小从上到下按行排列成矩阵, 取前 k 行组成矩阵 P ;
6. $Y = PX$ 即为降维到 k 维后的数据。

■ 主成分分析(PCA)

- 缓解维度灾难：PCA 算法通过舍去一部分信息之后能使得样本的采样密度增大（因为维数降低了），这是缓解维度灾难的重要手段；
- 降噪：当数据受到噪声影响时，最小特征值对应的特征向量往往与噪声有关，将它们舍弃能在一定程度上起到降噪的效果；
- 过拟合：PCA 保留了主要信息，但这个主要信息只是针对训练集的，而且这个主要信息未必是重要信息。有可能舍弃了一些看似无用的信息，但是这些看似无用的信息恰好是重要信息，只是在训练集上没有很大的表现，所以 PCA 也可能加剧了过拟合；
- 特征独立：PCA 不仅将数据压缩到低维，它也使得降维之后的数据各特征相互独立


■ 线性编码(Linear Coding, LC)

- 给定一组基向量 $A = [\mathbf{a}_1, \dots, \mathbf{a}_M]$, 将输入样本 $\mathbf{x}$ 表示为这些基向量的线性组合

$$\mathbf{x} = \sum_{m=1}^M z_m \mathbf{a}_m$$
$$= \mathbf{A}\mathbf{z},$$

字典(dictionary)

编码(encoding)



编码是对 D 维空间中的样本 $\mathbf{x}$ 找到其在 P 维空间中的表示（或投影），其目标通常是编码的各个维度都是统计独立的，并且可以重构出输入样本。编码的关键是找到一组“完备”的基向量 $\mathbf{A}$ ，比如主成分分析等。但是主成分分析得到的编码通常是稠密向量，没有稀疏性。

无监督学习-->无监督特征学习


■ 完备性

数学小知识 | 完备性

如果 M 个基向量刚好可以支撑 M 维的欧氏空间, 则这 M 个基向量是完备的. 如果 M 个基向量可以支撑 D 维的欧氏空间, 并且 $M > D$, 则这 M 个基向量是过完备的 (overcomplete)、冗余的.

“过完备”基向量是指基向量个数远远大于其支撑空间维度. 因此这些基向量一般不具备独立、正交等性质.

Sparse coding illustration



稀疏编码

找到一组“过完备”的基向量 (即 $M > D$) 来进行编码。

■ 稀疏编码(Sparse Coding, SC)

- 给定一组N个输入向量 $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(N)}$, 其稀疏编码的目标函数定义为

$$\mathcal{L}(\mathbf{A}, \mathbf{Z}) = \sum_{n=1}^N \left(\left\| \mathbf{x}^{(n)} - \mathbf{A}\mathbf{z}^{(n)} \right\|^2 + \eta \rho(\mathbf{z}^{(n)}) \right)$$

- $\rho(\cdot)$ 是一个稀疏性衡量函数, η 是一个超参数, 用来控制稀疏性的强度。

$$\rho(\mathbf{z}) = \sum_{i=1}^p \mathbf{I}(|z_i| > 0)$$

$$\rho(\mathbf{z}) = \sum_{i=1}^p -\exp(-z_i^2)$$

$$\rho(\mathbf{z}) = \sum_{i=1}^p |z_i|$$

$$\rho(\mathbf{z}) = \sum_{i=1}^p \log(1 + z_i^2)$$

■ 稀疏编码(Sparse Coding, SC)

- 稀疏编码的训练过程一般用交替优化的方法进行

1) 固定基向量 $\mathbf{A}$, 对每个输入 $\mathbf{x}^{(n)}$, 计算其对应的最优编码


$$\min_{\mathbf{z}^{(n)}} \left\| \mathbf{x}^{(n)} - \mathbf{A}\mathbf{z}^{(n)} \right\|^2 + \eta \rho(\mathbf{z}^{(n)}), \forall n \in [1, N].$$

2) 固定上一步得到的编码 $\{\mathbf{z}^{(n)}\}_{n=1}^N$, 计算其最优的基向量


$$\min_{\mathbf{A}} \sum_{n=1}^N \left(\left\| \mathbf{x}^{(n)} - \mathbf{A}\mathbf{z}^{(n)} \right\|^2 \right) + \lambda \frac{1}{2} \|\mathbf{A}\|^2,$$

其中第二项为正则化项, λ 为正则化项系数.

■ 稀疏编码(Sparse Coding, SC)



图像






稀疏编码的
每一维都可
以被看作一
种特征

■ 稀疏编码(Sparse Coding, SC)

- 计算量
 - 稀疏性带来的最大好处就是可以极大地降低计算量。
- 可解释性
 - 因为稀疏编码只有少数的非零元素，相当于将一个输入样本表示为少数几个相关的特征。这样我们可以更好地描述其特征，并易于理解。
- 特征选择
 - 稀疏性带来的另外一个好处是可以实现特征的自动选择，只选择和输入样本相关的最少特征，从而可以更好地表示输入样本，降低噪声并减轻过拟合。

■ 自编码器(Auto-Encoder)

- 自编码器是一类在半监督学习和无监督学习中使用的人工神经网络，其功能是通过将输入信息作为学习目标，对输入信息进行表征学习
- 自编码器包含编码器(Encoder)和解码器(Decoder)两部分



■ 自编码器(Auto-Encoder)


- 按学习范式，自编码器可以被分为收缩自编码器、正则自编码器和变分自编码器，其中前两者是判别模型、后者是生成模型
- 按构建类型，自编码器可以是前馈结构或递归结构的神经网络
- 自编码器具有一般意义上表征学习算法的功能，被应用于降维和异常值检测
- 包含卷积层结构的自编码器可被应用于计算机视觉问题，包括图像降噪、神经风格迁移等

■ 自编码器(Auto-Encoder)

- 自编码器是一个输入和输出相同的神经网络,给定输入空间和特征空间,自编码器求解两者的映射使输入特征的重建误差达成最小:

$$\left. \begin{aligned} y &= h(x) \\ r &= f(y) = f(h(x)) \end{aligned} \right\} \text{重建误差最小}$$


- 求解完成后,由编码器输出的隐含层特征,即“编码特征”可视为输入数据的表征



- 当自编码器的编码、解码能力很强时,可以确保对训练样本的完美重建,但却难以发现数据的内在分布和结构规律

■ 自编码器(Auto-Encoder)

➤ 去噪自编码器(Denoising Auto-Encoders, DAE)




降噪自编码器

(Denoising Auto-Encoder) 就是一种通过引入噪声来增加编码鲁棒性的自编码器，并提高模型的泛化能力

- 通常还可约束编码部分和解码部分的权重保持某种关系，比如捆绑约束(Tied Constraint)、稀疏约束(Sparse Constraint)等。

■ 自编码器(Auto-Encoder)

➤ 堆叠去噪自编码器(Stacked Denoising Auto-Encoders, SDAE)




深层神经网络作为自编码器提取的数据表示一般会更加抽象，能够更好地捕捉到数据的语义信息。在实践中经常使用逐层堆叠的方式来训练一个深层的自编码器，称为**堆叠自编码器**。堆叠自编码器一般可以采用**逐层训练**（Layer-Wise Training）来学习网络参数

- 引入了更多的隐藏层，反复堆叠，从而获得了更多输入数据的深层次和抽象化特征。

■ 自编码器(Auto-Encoder)

➤ 欠完备自编码器(Unncomplete Auto-Encoders, UAE)



➤ 编码维度小于输入维度的自编码器。学习欠完备的表示将强制自编码器捕捉训练数据中最显著的特征。

PART TWO

概率密度估计

Probability Density Estimation



■ 概率密度估计：基于一些观测样本来估计一个随机变量的概率密度函数

- 参数密度估计(Parametric Density Estimation)

- 根据先验知识假设随机变量服从某种分布，然后通过训练样本来估计分布的参数。
- 估计方法：最大似然估计

$$\log p(\mathcal{D}; \theta) = \sum_{n=1}^N \log p(\mathbf{x}^{(n)}; \theta).$$

- 非参数密度估计(Nonparametric Density Estimation)

- 不假设数据服从某种分布，通过将样本空间划分为不同的区域并估计每个区域的概率来近似数据的概率密度函数。

参数密度估计

• 正态分布

假设样本 $\mathbf{x} \in \mathbb{R}^D$ 服从正态分布

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{D/2}|\boldsymbol{\Sigma}|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right),$$

其中 $\boldsymbol{\mu}$ 和 $\boldsymbol{\Sigma}$ 分别为正态分布的均值和方差.

数据集 $\mathcal{D} = \{\mathbf{x}^{(n)}\}_{n=1}^N$ 的对数似然函数为


$$\log p(\mathcal{D}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = -\frac{N}{2} \log\left((2\pi)^D |\boldsymbol{\Sigma}|\right) - \frac{1}{2} \sum_{n=1}^N (\mathbf{x}^{(n)} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}^{(n)} - \boldsymbol{\mu}).$$

分别求上式关于 $\boldsymbol{\mu}, \boldsymbol{\Sigma}$ 的偏导数, 并令其等于 0. 可得,

$$\boldsymbol{\mu}^{ML} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}^{(n)},$$

$$\boldsymbol{\Sigma}^{ML} = \frac{1}{N} \sum_{n=1}^N (\mathbf{x}^{(n)} - \boldsymbol{\mu}^{ML})(\mathbf{x}^{(n)} - \boldsymbol{\mu}^{ML})^\top.$$

当 $h=1$ 时的二维正态概率密度曲面



■ 参数密度估计

• 多项分布

数据集 $\mathcal{D} = \{\mathbf{x}^{(n)}\}_{n=1}^N$ 的对数似然函数为

$$\log p(\mathcal{D}|\boldsymbol{\mu}) = \sum_{n=1}^N \sum_{k=1}^K x_k^{(n)} \log(\mu_k). \quad (9.34)$$


多项分布的参数估计为约束优化问题. 引入拉格朗日乘子 λ , 将原问题转换为无约束优化问题.

$$\max_{\boldsymbol{\mu}, \lambda} \sum_{n=1}^N \sum_{k=1}^K x_k^{(n)} \log(\mu_k) + \lambda \left(\sum_{k=1}^K \mu_k - 1 \right). \quad (9.35)$$

分别求上式关于 μ_k, λ 的偏导数, 并令其等于 0. 可得,

$$\mu_k^{ML} = \frac{m_k}{N}, \quad 1 \leq k \leq K \quad (9.36)$$

其中 $m_k = \sum_{n=1}^N x_k^{(n)}$ 为数据集中取值为第 k 个状态的样本数量.



■ 参数密度估计存在问题

- 模型选择问题
 - 如何选择数据分布的密度函数？
 - 实际数据的分布往往是非常复杂的，而不是简单的正态分布或多项分布。
- 不可观测变量问题
 - 即我们用来训练的样本只包含部分的可观测变量，还有一些非常关键的变量是无法观测的，这导致我们很难准确估计数据的真实分布。
- 维度灾难问题
 - 高维数据的参数估计十分困难
 - 随着维度的增加，估计参数所需要的样本数量指数增加。在样本不足时会出现过拟合。

■ 参数密度估计存在问题

- 模型选择问题
 - 如何选择数据分布的密度函数？
 - 实际数据的分布往往是非常复杂的，而不是简单的正态分布或多项分布。
- 不可观测变量问题
 - 即我们用来训练的样本只包含部分的可观测变量，还有一些非常关键的变量是无法观测的，这导致我们很难准确估计数据的真实分布。
- 维度灾难问题
 - 高维数据的参数估计十分困难
 - 随着维度的增加，估计参数所需要的样本数量指数增加。在样本不足时会出现过拟合。

■ 非参数密度估计

- 对于高维空间中的一个随机向量 $\mathbf{x}$ ，假设其服从一个未知分布 $p(\mathbf{x})$ ，则 $\mathbf{x}$ 落入空间中的小区域 $\mathcal{R}$ 的概率为

$$P = \int_{\mathcal{R}} p(\mathbf{x}) d\mathbf{x}.$$

- 给定 N 个训练样本 $D = \{\mathbf{x}^{(n)}\}_{n=1}^N$ ，落入区域 $\mathcal{R}$ 的样本数量 K 服从二项分布

$$P_K = \binom{N}{K} P^K (1 - P)^{1-K},$$

当 N 非常大时，我们可以近似认为

$$P \approx \frac{K}{N}$$

假设区域 $\mathcal{R}$ 足够小，其内部的概率密度是相同的，则有， V 为区域 $\mathcal{R}$ 的体积

$$P \approx p(\mathbf{x})V$$


结合上述两个公式，得到

$$p(\mathbf{x}) \approx \frac{K}{NV}$$


■直方图方法(Histogram Method)

- 一种非常直观的估计连续变量密度函数的方法，可以表示为一种柱状图。

以一维随机变量为例，首先将其取值范围分成 M 个连续的、不重叠的区间 (bin), 每个区间的宽度为 Δ_m . 给定 N 个训练样本 $\mathcal{D} = \{x^{(n)}\}_{n=1}^N$, 我们统计这些样本落入每个区间的数量 K_m , 然后将它们归一化为密度函数.




(a) 10 个区间 (bin)



(b) 30 个区间 (bin)

■核密度估计(Kernel Density Estimation)

- 核密度估计是一种直方图方法的改进。
 - 也叫Parzen窗方法



- 假设 $\mathcal{R}$ 为d维空间中的一个以点 $\mathbf{x}$ 为中心的“超立方体”，并定义核函数来表示一个样本 $\mathbf{z}$ 是否落入该超立方体中

$$\phi\left(\frac{\mathbf{z} - \mathbf{x}}{h}\right) = \begin{cases} 1 & \text{if } |z_i - x_i| < \frac{H}{2}, 1 \leq i \leq D \\ 0 & \text{else} \end{cases}$$

H 为超立方体的边长

- 点 $\mathbf{x}$ 的密度估计为 $p(\mathbf{x}) = \frac{K}{NH^D} = \frac{1}{NH^D} \sum_{n=1}^N \phi\left(\frac{\mathbf{x}^{(n)} - \mathbf{x}}{H}\right)$
 H^D 表示超立方体 $\mathcal{R}$ 的体积.

■K近邻方法(K Nearest Neighbour Method)

- 核密度估计方法中的核宽度是固定的，因此同一个宽度可能对高密度的区域过大，而对低密度区域过小。
- 一种更灵活的方式是设置一种可变宽度的区域，并使得落入每个区域中样本数量为固定的K。
- 要估计点 x 的密度，首先找到一个以 x 为中心的球体，使得落入球体的样本数量为K，就可以计算出点 x 的密度。

■思考

- 估计以下三种密度函数的区别: $p(x)$, $p(y|x)$ and $p(x|y)$?
 - 生成模型Generative model
 - 判别式模型Discriminative model
- 最大似然函数的本质是什么?
 - 真实数据分布 $p_r(x)$
 - 模型数据分布 $p_\theta(x)$

■非参数密度估计存在问题

- 非参数密度估计(直方图方法除外)需要保留整个训练集。
- 而参数密度估计不需要保留整个训练集，因此在存储和计算上更加高效。

03

PART THREE

小结

Summary



■ 小结

➤ 无监督特征学习

- ✓ 主成分分析
- ✓ 稀疏编码
- ✓ 自编码器
- ✓ 稀疏自编码器
- ✓ 降噪自编码器

➤ 概率密度估计

- ✓ 参数密度估计
- ✓ 非参数密度估计(核方法, **K**近邻法)